

國家科學及技術委員會補助
大專學生研究計畫研究成果報告

計 畫
： 基於外部知識的攻擊性迷因辨識框架
名 稱

報 告 類 別 ： 成果報告
執行計畫學生： 陳冠廷
學生計畫編號： NSTC 112-2813-C-006-020-E
研 究 期 間 ： 112年07月01日至113年02月29日止，計8個月
指 導 教 授 ： 高宏宇

處 理 方 式 ： 本計畫可公開查詢

執 行 單 位 ： 國立成功大學資訊工程學系（所）

中 華 民 國 113年03月26日

目錄

1	前言.....	1
2	研究目的.....	1
3	文獻探討.....	2
3.1	相關資料集.....	2
3.2	惡意迷因識別 (Hateful Memes Detection)	3
3.3	外部知識 (External Knowledge)	3
3.4	預訓練模型 (Pretrained Model)	4
3.4.1	BERT 相關之預訓練模型.....	4
3.4.2	多模態圖文預訓練模型.....	4
3.5	提示學習 (Prompt Learning)	5
4	研究方法.....	6
4.1	資料集分析.....	6
4.2	問題定義與評價指標.....	8
4.3	外部特徵生成	10
4.3.1	圖像描述 (Image Captioning)	10
4.3.2	人物性別與種族偵測	11
4.3.3	圖像的關鍵實體	11
4.3.4	惡意詞彙.....	11
4.3.5	外部特徵的示例.....	12
4.4	模型與訓練方法.....	13
4.4.1	CLIP.....	13
4.4.2	Bert-based	15
5	結果與討論	17
5.1	實驗結果探討	17
5.1.1	多模態 CLIP 方法.....	17
5.1.2	BERT-based 方法.....	18
5.1.3	與其他方法比較	19
5.2	錯誤分析	20
5.2.1	錯誤統計.....	21
5.2.2	錯誤案例之關鍵字分析.....	23
5.3	結論與未來發展.....	24
6	參考文獻.....	25

摘要

迷因作為新世代的溝通媒介，透過隱晦的描述結合圖像內容，產生詼諧的意涵來勾起讀者共鳴。然而，迷因卻也可能將詼諧建構在他人的痛楚上，成為一種惡意迷因。迷因的理解經常需要多層理解，如歷史淵源、惡意文字、實體關聯等過程，而且經常圖文不相符。

考量到多數的多模態模型涵蓋偌大的參數量而且預訓練於圖文相符的資料居多，並不是最適合迷因辨識的預訓練模型。我認為現有的語言模型有一定的語意理解能力，只要提供好的語言特徵可以引導模型用正確的隱性知識來推理。本研究以現有的方法為圖像內容產生外部特徵，並用語言模型結合提示學習的方法來辨識惡意迷因，僅用相對少的參數量就達到了有競爭力的表現。最後，報告也分析了外部特徵對語言模型表現的影響，並為未來發展給出了一些想法。

關鍵字：惡意迷因辨識、外部特徵、提示學習

警告：研究報告中涵蓋相關攻擊性內容。

Abstract

Memes, as a new generation of communication media, combine obscure descriptions with image content to produce humorous meanings that resonate with readers. However, memes can also become malicious by playing humors on the suffering of others. Understanding memes often requires multiple levels of understanding, such as historical origins, malicious text, entity associations, etc., and often the images and text do not match.

Considering that most multimodal models cover a large number of parameters and are mostly pretrained on matching images and text, they are not the most suitable pretrained models for meme recognition. I think existing language models have certain semantic understanding capabilities. If good language features are provided, the model can be guided to reason with correct implicit knowledge. This study uses existing methods to generate external features of image content and uses language models combined with prompt learning methods to identify hateful memes. It uses only a relatively few parameters to achieve competitive performance. In the end, the report also analyzes the impact of external features on language model performance and gives some tips for future works.

keywords: hateful meme detection, external features fusion, prompt learning

warnings: this research report covers some offensive content.

1 前言

基於網路的普及化，社群媒體已然成為我們生活中不可或缺的部分，更有效地縮短了人與人的溝通距離。根據 2016 年的一項研究，臉書 (Facebook) [1] 指出其網路平台的平均直徑長是 4.57。換言之，在社群媒體中，一則訊息只需透過適當的 5 個人便有機會迅速散播至全世界。然而，如此密集的網路連結同時也加速了錯誤訊息和惡意言論的傳播，因此如何自動化地過濾不當的網路訊息成為一個重要議題。

近年來，迷因 (Memes) 成為了一種新興的訊息傳播形式，透過在圖片中添入相關聯的文字，迷因能夠勾起閱讀者的共鳴和認同。有趣的迷因確實會讓人會心一笑，但是當其具有攻擊性或歧視性時，我們或許就要反思它存在的必要性，並遏止這類的所謂的「地獄梗圖」[2][3]。要使電腦能夠理解迷因並非易事，迷因需要同時理解圖像內容和迷因內文，而且需要通過多層次的常識來理解迷因的內涵。例如，惡意迷因可能以希特勒的圖片攻擊猶太人，或在伊斯蘭宗教的圖像上添加有關恐怖攻擊的文字等。本研究旨在利用現有的圖像描述和檢索技術，提取出圖像的關鍵內容，並且利用惡意字典來提供文字內容的潛在攻擊目標，將原本多模態的任務轉換為純文字的任務，並借助語言模型習得的隱性知識來辨識是否為惡意迷因。

2 研究目的

惡意迷因辨識是一項極具挑戰性的任務，而目前的研究方法尚有很大的改進空間。迷因識別可視為一種多模態理解的過程，但又別於圖像描述與圖像生成兩種任務。圖像描述和生成都是預期文字與圖片是直接相關的，而迷因則更多地涉及到「多跳」(multi-hop)理解的關係，而導致圖文經常不直接相符。迷因通常會在圖像中加入相關聯的文字，而這些文字通常與圖片並不直接相關，而需要透過常識、歷史淵源、圖像意境來理解迷因。

迄今為止，現有的 state-of-the-art 方法都採用多模態的模型來辨識迷因，只有非常少數的研究題及語言模型對惡意迷因辨識的影響和引入適當的外部特徵和知識。本研究考慮到現有的多模態預訓練模型通常是在與圖文內容相符的資料集上進行預訓練，加上預訓練的目標多著重於圖文比對和圖像描述任務，因此直接將這些模型應用在迷因資料集上，會導致下游任務與預訓練的資料和方法相佐，難以實現真正的迷因理解。另一方面，許多性能優秀的多模態模型都非常龐大，對於一般的研究者而言並沒有足夠的運算資源來執行模型，更不用提想要修改架構或是微調參數。

有鑑於多模態與電腦視覺的其他研究已十分成熟，本研究採用現有的圖像描述和檢索技術來將圖像內容轉換為文字內容，也就是盡可能的以語言的方式來表示圖像，並且引入惡意語意的辭典(HurtLex)提供文字的潛在攻擊目標。由於遮罩語言模型(masked language modeling, 簡寫

為 MLM)透過填空的方式訓練在大量的人類語料，像是維基百科、新聞、社群平台的貼文等等，某種程度上具有了解字詞和句子的關係。本研究利用 MLM 並結合提示學習(prompt-based learning)與上下文學習(in-context learning)的技術微調模型，用以了解語言模型與適當的外部特徵在惡意迷因辨識的表現，並將其和經典的多模態模型 CLIP 做詳細比較。除此之外，本研究也進一步地探討了以下幾個主題，為後續相關的研究提供有用的資訊：

- 一、透過不同的技術來探討經典的多模態模型 CLIP 在惡意迷因辨識的性能，驗證對比學習的方式在此任務的侷限性，並與語言模型的表性做對比。
- 二、探究不同外部因素和語言模型對惡意迷因辨識的影響，了解甚麼樣的特徵是有助於惡意迷因識別，以及何種預訓練語言模型更適合此任務。
- 三、藉由錯誤案例來分析本研究提出的方法在此任務上的發展前景和缺陷，並提供未來可以嘗試的改進方法。

3 文獻探討

3.1 相關資料集

惡意迷因的資料集並不像圖像描述的资料集一樣容易取得，尤其是在資料的質量上需要有嚴格的控管。像是對於「惡意」的定義常常是模糊的，需要有良好的且公信的標記方法。另外，迷因也應該盡可能地需要跨模態的理解，如果大多數資料的文字內容就已有攻擊性，容易使資料過於簡單。因此，高質量的惡意迷因資料集數量目前仍非常有限，其中以 Facebook Hateful Memes 資料集（縮寫為 FHM）[4]最具代表性。Kiela 等人[4]在建構 FHM 資料集時，考慮了多模態理解的重要性。他們為了避免單一模態的模型即可以有很好的性能，特別設計與篩選資料集，使資料中存在同圖不同文與同文不同圖的狀況，並且用語意反轉標籤[圖一]。Mathias 等人在隔年又針對 FHM 資料集增加了更細節的標籤，添加了惡意迷因攻擊的目標與攻擊類型[5]，可助於更深入去探討辨識結果與錯誤分析。Bassignana 等人透過半自動化的方法建構多語言的惡意字典 HurtLex [6]，希冀成為惡意言論辨識的一項新工具，並標記這些字詞的潛在攻擊對象。例如：nigga 是對一種有色人種的攻擊、lummoX 是一種人身攻擊的字典。



圖一、FHM 資料集的資料強化示例。左邊的圖與中間的圖為臭鼬，但是根據文字

描述可以發現中間是一種惡意的迷因，而左邊不是。同理，相同文字但右邊的花朵圖片，使得迷因變為非惡意的迷因。

3.2 惡意迷因識別 (Hateful Memes Detection)

FHM 資料集在提出的同時，提供了非常多的基準方法 (baseline methods) [4]，其中包括只考慮單一模態的 BERT 和 ResNet 分類器、融合兩種模態特徵的方法，以及微調多模態預訓練的分類器，Kiela 等人證實了考慮多模態的方法能取得較好的表現。Muennighoff [7]則利用模型集成(model ensembling)的方式，將 19 個微調後的多模態模型的預測結果進行整合，其中包括了 VisualBERT, OSCAR, UNITER, ERNIE 四種模型結構，最後取得該比賽的第二名。Zhou 等人[8]提出了一種新的模型架構，將圖片描述、迷因文字、物件偵測三種特徵同時輸入至 triplet-relation network 中，並採用交互注意力運算 (cross-attention) 來訓練模型，以獲取辨識結果。另外，近期興起的多模態大型語言模型也在 FHM 資料集上展現了卓越的表現。Alayrac 等人提出的 Flamingo [9]僅透過少數樣本學習 (few-shot learning)，就取得媲美多模態 baseline 的分數。除了多模態的方法外，也有探討語言模型與提示學習的方法出現。Cao 等人提出 PromptHate [10]的框架，從資料集中隨機選出正例和負例作為示例，並設計簡單的提示詞 (如：It was hate/normal)，採取提示學習的演算法來微調 RoBERTa 參數，透過集成不同示例的預測結果，在 FHM 和 HarMeme 兩個資料集上都達到了有競爭力的表現。

3.3 外部知識 (External Knowledge)

基於深度學習的崛起，端到端的訓練方式 (end-to-end training) 已逐漸取代早期的特徵工程，並顯著提升了模型的性能。然而，導入與特定任務相關的外部知識能夠進一步增強端到端模型的訓練效果，透過有效的顯性特徵有助於緩解過擬合 (overfitting) 問題。舉例而言，在問答任務中，常識性問答可通過合適的常識資料庫來提升模型性能。Wu 等人[11]利用 DBpedia 作為外部知識源來增強圖像問答模型的性能。他們通過檢索與圖片屬性相關的文章，採用 Doc2Vec 演算法將文章向量化，並將其與圖片屬性、描述和問題一同輸入 LSTM 模型，以獲得問題的答案。在當時的 COCO-QA 資料集上，該方法達到了最先進的性能。另一方面，Yichao 等人[12]則利用 conceptnet 作為外部知識來源，通過構建圖像描述和問題的 conceptnet 子圖，並利用多模態的注意力結構將知識圖譜、圖像和問題的向量相融合，以回答問題。在 OK-VQA 資料集上，該方法超越了多數基準方法。除了常識知識庫外，Koufakou 等人考慮到惡意言論偵測 (abusive language detection) 可用標住過的惡意詞彙[5]來增強語言模型的性能[13]。他們採用簡單的計數向量統計字詞潛在的攻擊對象，將轉換的

稀疏向量用神經網路編碼成低微度的特徵向量，將其與 BERT 特徵拼接預測分類結果，在多個惡意言論的資料都有一定程度的性能提升。

3.4 預訓練模型（Pretrained Model）

預訓練模型是一種已在相同型態的資料習得一定知識表示的模型，預訓練的過程是希望用有效的目標函數使模型在大量資料上學習出有效的知識，並且可以用微調參數的方法輕鬆轉移到各種下游任務上，即所謂的轉移學習（transfer learning）。可想而知，擁有優秀的預訓練模型才能有優秀的下游任務表現，而如何訓練出好的預訓練模型就在於如何取得並使用大量高質量的資料和有效的訓練目標。以下根據本研究需求，探討兩類的預訓練模型：

3.4.1 BERT 相關之預訓練模型


自然語言處理（natural language processing，簡稱為 NLP）的任務自 BERT 興起後有了重大的突破，並在當時的 NLP 任務取得最先進的表現。Devlin 等人[14]認為理解文字就在於懂得如何在空缺的文字段落中填入適當的文字，以及了解句子之間的連接關係，他們將其定義為遮罩語言模型(MLM)與下個句子的預測(NSP)兩種任務，在 BooksCorpus 和 Wikipedia 兩種語料上訓練 BERT 模型。Liu 等人則是針對 BERT 模型做了改進提出另一個語言模型 RoBERTa [15]，他們引入更多且豐富的語料，並且採用動態的 MLM 改進 BERT 使用的靜態 MLM，同時移除了 NSP 的任務，在下游任務達到比 BERT 更優秀的性能。

由於多數任務都是利用預訓練模型微調在下游任務的資料上，所以有一個良好的預訓練模型可以在下游任務表現更好。有鑑於一般的 BERT 類模型皆預訓練於廣泛的人類語料（Wikipedia, BooksCorpus 等），對特定領域的詞彙和語句並不了解，因此在醫療、法律甚至是惡意言論資料上微調的表現通常不佳。Gururangan 等人率先提出了繼續預訓練（continual pretraining）[16]的思維，將 RoBERTa 以原始預訓練的方式繼續訓練在特定領域的語料上，其中包括了生物醫學、電腦科學、新聞和評論四種領域，最終在四種領域的下游任務超越了原始 RoBERTa 的性能。此外，他們也發現當領域與原始預訓練的差異越大時，通常繼續預訓練的表現會提升更多，生物醫學與電腦科學兩個領域的效果更顯著，反之，因為一般的語料庫內容較生活化，所以與新聞、評論內容接近，繼續預訓練的效果較不顯著。Caselli 等人也在同年訓練了 HateBERT [17]，蒐集大量在 Reddit 平台上惡意的言論，一樣採用繼續預訓練的技術將 BERT 訓練在惡意言論上，並證實於惡意言論偵測的任務上有較佳的性能。

3.4.2 多模態圖文預訓練模型

隨著電腦視覺和自然語言處理的發展日益成熟，圖文結合的多模態任務強調將影像與文字的特徵有效地融合，並衍生出了多種方法。如聯合表示（joint representation）和協調表示（coordinated representation）等方法[18]。聯合表示主要著重於將單一模態的表示通過向量運算進行融合，例如拼接向量、最大值、平均值、外積等方法；而協調表示則強調通過相似度來約束兩種模態的表示，以達到類似於特徵對齊（representation alignment）的效果。

除了融合特徵的方式外，研究人員還將預訓練的概念應用到多模態任務上。Li 等人提出了 VisualBERT [19]的方法，允許 BERT 的輸入端可以放入圖片，沿用 MLM 和 NSP 任務來對齊圖片與文字表示，被視為許多多模態任務的基準方法。Radford 等人提出的 CLIP [20]模型，在網路上爬取了多達 4 億多的圖文對，採用對比學習（contrastive training）的方式顯性地對齊圖文特徵[圖二]。憑藉這種非常簡單的對比學習概念加上龐大的預訓練資料，CLIP 擁有非常驚人的零樣本分類能力，在眾多的圖像資料集中都有突破性的表現。Li 等人則是改進了一些 CLIP 模型可能存在的問題，提出了 Blip 模型[21]。他們認為網路資料的文字內容涵蓋較多雜訊，因此設計了相關演算法過濾掉有雜訊的資料；並採用多任務學習的方法改善文字生成的質量，讓模型在預訓練時做對比學習、圖文二元匹配和圖像描述，在當時的圖像描述任務上取得 SOTA 性能。



圖二、CLIP 模型預訓練的方法[20]。以 batch 大小N為例， $T_1 \sim T_N$, $I_1 \sim I_N$ 分別為文字和圖片的向量表示，而對比學習的目標就是盡可能地分辨相關的圖片（對角線上的為正例）與不相關的圖片（非對角線上的為負例）。

3.5 提示學習(Prompt Learning)

預訓練模型加上微調參數成為許多研究的起手式，但是這種方法使預訓練的目標與下游微調的目標不相同、沒有使用到語言的隱性知識、也會導致模型過大而難以微調的窘境。提示學習改善了這些缺陷，Liu 等人[22]統整了提示學習的演算法，並將這種新的流程定義成 pre-train, prompt, predict。對於 BERT 這類的語言模型，可以使用所謂的填空式提示（cloze prompt）的方式來微調模型，例如可以使用”It was [MASK].”作為提示詞接在原輸入後方，接著根據任務需求篩選預期[MASK]裡的字詞，透過訓練的方式使[MASK]的分布更貼近下游任務需求。藉由填空式的提示學習，上下游任務的形式得以統一，而且得以使用語意描述的方法訓練模型。提示學習的方法也不僅僅侷限於 MLM 的模型，生成式的語言模型也適用。

研究也發現提示詞的內容與順序對結果有很大的影響力[22] [23]，而且常常人類直觀的提示詞並不一定帶來最好的效益，因此有了動態提示詞的相關演算法。另一方面，Gao 等人[23]發現適當的給模型一些示例作為上下文提示，可以引導模型更能達到預期的輸出，甚至在少樣本上就可以達到有競爭力的表現。

Ding 等人發現 prompt learning 的前景與實作上的繁瑣細節，他們於 2021 年開發了開源框架 OpenPrompt [24]，使開發者可以用更高層級的封裝來使用提示學習的技術，本研究建立於此開源軟體做更進一步地的實驗研究。

4 研究方法

4.1 資料集分析

由於比賽平台 DrivenData 已關閉上傳且 FHM 之測試資料並未公開，目前僅能取得 FHM 的訓練資料與開發資料，因此所有的實驗皆以開發資料的表現為依據。FHM 訓練資料有 8500 筆而開發資料為 500 筆，資料格式如[表一]所示共有 4 個欄位。其中 img 欄位表示圖片的路徑並以 id 為檔案名稱、label 為二元變數（0：非惡意迷因；1：惡意迷因）、text 為迷因中的文字。基於此資料集已給予迷因中的文字，因此無須再對資料利用 OCR 的方式辨識文字。

id	img	label	text
42953	img/42953.png	0	its their character not their color that matters
23058	img/23058.png	0	don't be afraid to love again everyone is not ...
13894	img/13894.png	0	putting bows on your pet

表一、FHM 資料的格式。

首先，我透過簡單的資料分析，探索了資料集標籤的分布狀況和特色。根據[圖三]所示，訓練資料的非惡意迷因數量約為惡意迷因數量的 2 倍，而開發資料則約為 1:1 的分布，這樣的分布情況顯示資料集的標籤平衡性良好。接下來，我統計惡意迷因與非惡意迷因的字詞，探究惡意迷因是否涵蓋特定的關鍵字，並使用文字雲（wordcloud）的方式呈現。為了處理語句中的停頓詞（stopwords），例如代名詞、助動詞和冠詞等，我先將其刪除，然後使用 TF-IDF 演算法來計算字詞的權重，以便製作文字雲[圖四]。根據文字雲可以發現非惡意迷因與惡意迷因有一些關鍵字的重疊，可能為此資料集強化的結果；而從惡意迷因的關鍵字分布可以發現其主題與種族、信仰和性別有非常大的關聯。TF-IDF 之演算法設計如下：


$$TFIDF = TF \times IDF \quad (1)$$

$$TF_{i,j} = \frac{n_{i,j}}{\sum_k n_{k,j}} \quad (2)$$

$$IDF_i = \log_2\left(\frac{|D|}{|\{k: t_i \in d_j\}|}\right) \quad (3)$$

其中 $n_{i,j}$ 代表第 i 個字出現在第 j 個迷因內文的次數、 D 是所有已清理的迷因內文集合、 t_i, d_j 分別表示第 i 個字與第 j 個迷因文字。TF-IDF 演算法將句子裡高頻字（TF）視為關鍵字，同時用 IDF 的分數來校正語言中常用的文字，使其分數更能找到句子中的關鍵字而不受到常用字的影響。


除了統計的方法外，我採取語意分析的方式去探討迷因的向量分布。BERT 於預訓練階段學習了 NSP 任務，使其有能力分辨句子間的關係[14]，我利用 BERT 將句子轉換成向量後，以平均單位向量代表整個句子，並設計了兩種方法來探究迷因的圖文相符情況。一種方法是將迷因的文字 T 與圖像描述 C 分別轉為向量 $\mathbf{x}_T$ 和 $\mathbf{x}_C$ ，利用內積運算衡量兩向量的相似度；另一種方法假設向量加法足以表示語意的疊加，我把迷因的文字 T 與圖像描述 C 以特殊字[SEP]區隔後，經 BERT 轉為向量 $\mathbf{x}_{T[SEP]C}$ ，再利用內積運算衡量 $\mathbf{x}_{T[SEP]C}$ 與 $\mathbf{x}_T + \mathbf{x}_C$ 之相似度，並採用直方圖的形式繪製相似度的分布。如[圖五]所示，左圖顯示無論惡意或非惡意迷因，其相似度值皆集中於 0~0.2 的區間，意味著迷因與圖像描述大多是無直接相關的，也驗證了迷因資料需要多跳理解的設定。此外，非惡意迷因可能較不需要多層次的關聯，而且圖文從語意來看比較相符，導致左圖偏右側的分布以非惡意的迷因佔比較高，右圖也一樣顯示了相同的效果。綜合兩圖，可以明顯發現兩種類別的分布不能簡單地分離，也就代表 BERT 僅依靠這樣的訊息是很難分辨兩種類別的，因而衍生出後續採用更多特徵的想法。



圖三、訓練資料和開發資料的標籤分布。



圖四、訓練資料上的文字雲（左圖是非惡意迷因、右圖是惡意迷因）。



圖五、兩種向量的相似度分析。左圖為第一種方法、右圖為另一種方式，其中迷因描述是透過 BLIP 模型[21]產生的，更細節的分析會在 4.3.1 提及。

4.2 問題定義與評價指標

惡意迷因辨識的任務為一種二分類問題。在 FHM 資料下可以定義為，給定迷因圖片 I 和迷因內文 T 去預測標籤 Y ， $\mathbf{y} \in \mathbb{R}^2$ 代表分類結果為非惡意與惡意迷因的分數。

另外，我定義 θ 為模型的參數、 E 表示此研究額外使用到的外部特徵，則二元分類的問題根據有無外部特徵可以定義成以下兩種不同的形式，也就是取找到最能夠符合迷因資料的分類分布 $\hat{y}$ ：

$$\hat{y} = \underset{y \in [0,1]}{\operatorname{argmax}} p_{\theta}(y|I, T) \quad (4)$$

$$\hat{y} = \underset{y \in [0,1]}{\operatorname{argmax}} p_{\theta}(y|I, T, E) \quad (5)$$


根據二元分類輸出的結果可以畫出[表二]的混淆矩陣。本次的任務，我同時使用 Area under the ROC curve（簡寫為 AUROC）和 Accuracy 兩種指標來衡量模型表現，但仍以 AUROC 為主要的評斷指標（FHM 資料集的主要排名指標）。Accuracy 即是模型的準確度，一般以分數大者或是 0.5 作為分類門檻後，根據[式(6)]的定義計算分數。然而 AUROC 相較於 Accuracy 更在乎模型的分辨能力，其同時衡量了各種可能的分類門檻而計算的綜合分數。AUROC 即為 ROC 曲線下的面積，其中 ROC 曲線是由 TPR 與 FPR [式(7)]繪製的圖形，一般而言，AUROC 在二分類任務中需大於 0.5 才是有意義的，否則比隨機猜測還要差勁[圖六]。

混淆矩陣		預測結果	
		1	0
實際答案	1	TP	FN
	0	FP	TN

表二、混淆矩陣在二分類問題中的四種可能。TP：答對的正例；FN：答錯的正例；FP：答錯的負例；TN：答對的負例。

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (6)$$

$$TPR = \frac{TP}{TP + FN}, FPR = \frac{FP}{FP + TN} \quad (7)$$



圖六、藍色線是正常的 ROC 曲線，橘色線為隨機猜測之 ROC 曲線，而圖色面積則該 ROC 曲線下的面積，即表示 AUROC 的值。

4.3 外部特徵生成

4.3.1 圖像描述 (Image Captioning)

最直接地把圖像資訊轉為文字的方法即為圖像描述的技術。在文獻[8]中，Zhou 等人就有引入迷因圖像描述來做為額外特徵。在此次的研究中，我使用了預訓練的 BLIP 模型生成圖像描述[圖七]。除了考量到 BLIP 在圖像描述的性能外，我也發現 BLIP 的模型相較於其他方法不容易受到迷因內文的影響。如 CLIPCap 會在生成描述時受到圖像中的文字干擾而輸出迷因中的文字或是連續輸出同一個字的窘境。



圖七、BLIP Captioning 的結果呈現。Caption 不會受到圖片的文字影響，同時描述的內容也有一定的水平，可以描述到圖片的色彩、動作等，但是仍是以宏觀的角度在描述圖片，例如使用”a man with a mustache”取代了希特勒。

4.3.2 人物性別與種族偵測

FHM 資料集是以社群媒體的角度出發，因此惡意內容以宗教、種族、性別、殘缺為主，而這也是社群媒體最重視的網路霸凌問題，希望藉有效地偵測方法來保護不一樣的使用者。我考慮到種族、宗教與性別常常是息息相關的，舉例來說，伊斯蘭教徒多為中東人且多以男性為強權，所以偵測圖像的人物種族與性別可能有助於理解迷因的內涵。我使用了 FairFace 的預訓練模型[25]，其方法以 ResNet-34 作為編碼器，輸出圖像中人物的種族、性別與年紀，其中種族的辨識有非常詳細的分類，包括了黑人、白人、拉丁裔、東亞、東南亞、中東、印度人七種人種。在先前的文字雲分析中，我發現並沒有看到年紀上歧視的關鍵字。因此考量到不相干的特徵會對表現產生重大影響，我過濾掉了年齡的特徵，只採用種族與性別的資訊。

4.3.3 圖像的關鍵實體

儘管圖像描述能夠呈現圖像的含義，特別是專注於動作和簡易物件，但大多僅能以宏觀角度描述圖片，無法提供更詳細的描述以滿足使用者需求。以希特勒的圖片為例[圖七]，圖像描述未提及有關希特勒的字眼，而是利用人物特徵來描述希特勒的外貌，我將此稱為關鍵實體辨識。可以想見，若未能辨識到這些關鍵實體，將難以引導模型使用正確的知識理解迷因。

鑑於關鍵實體的種類多樣，包括名人、歷史人物、標誌等各種實體，因此使用物件辨識並非可行之方法。在本研究中，我利用 Google Vision API 中的 Web Entity Detection 辨識可能存在的實體。Web Entity Detection 採用圖像檢索的方式，尋找與 Google 網路最相關的圖片，並回傳該圖片中相關的實體。透過這種方式，我們能夠獲得非常有效的圖像資訊。

4.3.4 惡意詞彙

HurtLex[6]唯一種多語言的惡意辭典，根據此任務我只使用英文文字的詞彙，同時移除原資料不會利用到的欄位，僅保留 lemma 和 category 兩個欄位，而生成以下的資料[表三]格式：

lemma	category	description
nigga	ps	negative stereotypes ethnic slurs

cross-breed	ps	negative stereotypes ethnic slurs
assplay	om	words related to homosexuality
...	...	...

表三、HurtLex 有使用到的欄位，其中 description 為 category 欄位的實際意義。



HurtLex 是以字詞的原形 (lemmatization) 紀錄的字典，因此要判斷迷因是否含有惡意詞彙時，首先需要將所有辭彙都還原成字詞的原形，再採用字串比對的形式來確認是否含有惡意詞彙。除了迷因的文字和描述外，我把實體檢索後的內容也用來識別是否含有惡意詞彙。另外，我認為比起將其以神經網路編碼的方式輸入給模型[13]，利用語言的形式來提示模型更合理一些，因此我將惡意詞彙與攻擊對象以語言的方式轉換為輸出。例如：nigga 是一種對種族有攻擊性的詞語，經過 HurtLex 轉換後，可以改成以下的提示字描述：nigga is about negative stereotypes ethnic slurs。

4.3.5 外部特徵的示例

根據 4.3.1 至 4.3.4 的外部特徵定義就可以為每一張迷因擴增對應的特徵，對於沒有特徵的內容我用簡單的”None”作為文字填補。

我用兩張簡單的圖例來呈現擷取外部特徵後的資料結果。如[圖八]的結果，可以看到外部特徵會涵蓋雜訊。像是第一個圖例就會看到有很多不相干的實體，像是花生過敏和性別認同等，也可以看到種族辨識的結果並不是兩個黑人而是三個。另一方面，有些外部特徵也可以提取到意想不到的內容。以第二張圖片為例，圖片中戰士寶劍上的徽章是「十字軍東征」的號誌，透過實體檢索的方式被找出來了。

由下圖也可以看出有些辨識的結果有可能是空值，為了使模型能夠讀懂每個特徵的位置資訊和不受到空值的干擾，實作上我會用簡單的”None”作為文字填補，並且把每一個外部特徵以 BERT 的特出保留字[SEP]區隔開來。



圖八、加入外部特徵後的圖片示例。第一、二行分別是迷因的文字和圖像描述、第三行為種族辨識的結果、第四行示 google API 辨識後取前五個實體、第五行則是 HurtLex 提供的潛在攻擊目標。

4.4 模型與訓練方法

本研究希望以經典的多模態模型 CLIP 與經典的 BERT-based 模型結果對比，來強調外部特徵的幫助效果。針對同一類模型，我也設計了多種預測和訓練方法才能更詳細地探究其差異與可行性。

4.4.1 CLIP

CLIP 為一種對比學習的預訓練模型，在研究中，我設計了對比式的零樣本分類[圖九]與參數微調[圖十]兩種架構。對於零樣本分類，我使用了兩個集合 $\mathcal{W}_{pos}$, $\mathcal{W}_{neg}$ 分別表示非惡意迷因與惡意迷因的分類字詞集合，並用 This is $\mathcal{W}_{pos}$ / $\mathcal{W}_{neg}$ 當作提示詞。提示詞經過 CLIP 的 text encoder 分別轉為文字


向量 $\mathbf{x}_{pos}$ 與 $\mathbf{x}_{neg}$ ；而迷因圖像會經過 CLIP 的 image encoder 轉為 $\mathbf{x}_{img}$ 。在零樣本分類中，我以向量相似度的分數輸入 softmax 函數作為分類的機率 $\hat{\mathbf{y}} \in \mathbb{R}^2$ ：

$$\begin{aligned}\hat{y}_0 &= \frac{\mathbf{x}_{pos}^T \cdot \mathbf{x}_{img}}{\mathbf{x}_{pos}^T \cdot \mathbf{x}_{img} + \mathbf{x}_{neg}^T \cdot \mathbf{x}_{img}} \\ \hat{y}_1 &= \frac{\mathbf{x}_{neg}^T \cdot \mathbf{x}_{img}}{\mathbf{x}_{pos}^T \cdot \mathbf{x}_{img} + \mathbf{x}_{neg}^T \cdot \mathbf{x}_{img}}\end{aligned}\quad (8)$$


對於 CLIP 微調的方法，我認為 CLIP 於預訓練階段強調圖文的比對任務並不適用於迷因任務上，因此我將 CLIP 轉換後的特徵層利用 MLP (Multi-layer Perceptron) 投影到新的維度再進行分類，最後可以將分類結果透過 softmax 函數轉為二分類機率。如此一來，我就可以得出訓練資料的預測分數 $\hat{\mathbf{y}} = f_{\theta}(\mathbf{x}) \in \mathbb{R}^2$ ，並根據真實標籤 $\mathbf{y} \in \mathbb{R}^2$ 計算出損失函數 $\mathcal{L}$ 來優化可學習的參數 θ ，訓練過程就是希望在現有的 N 筆資料下找出最佳的參數 θ^* ：

$$\mathcal{L}(\mathbf{y}, \hat{\mathbf{y}}) = y_0 \log(\hat{y}_0) + y_1 \log(\hat{y}_1) \quad (9)$$

$$\theta^* = \underset{\theta}{\operatorname{argmin}} \sum_{i=1}^N \mathcal{L}_{CLIP}(\mathbf{y}, f_{\theta}(\mathbf{x}_i)) \quad (10)$$



圖九、CLIP 零樣本分類的框架。



圖十、CLIP finetune 參數的架構。為了降低訓練的參數量和速度，我固定了 CLIP 的特徵層，使參數量從 431M 降到只需訓練 3M 的參數量。

4.4.2 Bert-based

我針對語言模型的部分設計了 finetuning 和 prompt learning 兩種學習方法[圖十一]， finetuning 就是簡單地使用[CLS]接上 MLP 分類層分出兩個類別。而 prompt learning 則是利用 MLM 微調的方式來訓練模型參數。對於 prompt learning 的方法，我使用 MLM 的形式將分類的類別用[MASK]代替，並在經過 BERT 轉換後的向量去看[MASK]文字分布，並利用 Verbalizer 只取出 $\mathcal{W}_{pos}$, $\mathcal{W}_{neg}$ 兩種字的出現機率並用 softmax 標準化至 0-1 區間來表示分類結果。


由於語言模型 BERT 可以用[SEP]切開不同的句子作為輸入，來提供語言模型更多訊息。我用 p 來表示提示詞，其中提示詞可以將 4.3 所提到的特徵隨機組合並以[SEP]分隔後再加入 It was [MASK]，像是 p 可以是”two children sitting on a bench eating fruit [SEP] Black Male Black Male Black Male [SEP] It was [MASK]”，這樣分類的結果就可以轉換為以下的表達式：

$$\begin{aligned}\hat{y}_0 &= P([MASK] = \mathcal{W}_{pos} | p) \\ \hat{y}_1 &= P([MASK] = \mathcal{W}_{neg} | p)\end{aligned}\tag{11}$$


並使用[式(9)]來計算損失函數並更新 MLM 模型之參數：

$$\theta^* = \underset{\theta}{argmin} \sum_{i=1}^N \mathcal{L}_{MLM}(\mathbf{y}, f_{\theta}(\mathbf{x}_i))\tag{12}$$

考慮到不同預訓練的語言模型訓練於不同的主題的語料，可能會對下游任務產生不一樣的結果，因此我也分別使用了 2 個 MLM 的語言模型來探究其影響，分別為 BERT 和 HateBERT。例如：同樣用 The goal of life is [MASK]輸入兩種語言模型中會發現一般的 BERT 輸出的結果較正常，但是 HateBERT 傾向用更負面的詞彙[圖十二]。



圖十一、MLM 微調與提示學習的模型框架。



圖十二、不同 MLM 預訓練的知識差異。

4.5 實驗細節

由於實驗方法眾多，我僅在固定的超參數下微調模型，而沒有做更細緻地超參數調整，兩種模型的訓練參數設定如[表四]所示，並以 PyTorch 和 OpenPrompt 兩種開源的深度學習框架來訓練模型。

訓練相關的超參數	參數值	
	BERT-based	CLIP
Epochs	4	10
Batch size	8	64
Learning rate	0.00001	0.0001
Weight decay	0.01	0.0001
Loss	Cross Entropy	
Optimizer	AdamW	
Scheduler	CosineAnnealingLR	

表四、超參數設定的數值。

本次實驗之內容皆運行於 Kaggle 平台上，實際的硬體環境為 30G RAM, P100 16G GPU。另外，為了使實驗能盡可能地重現原始的結果（SEED=2024），我將所有過程中的隨機因素都盡量設定了亂數種子，同時將程式碼開源於下方連結：

<https://github.com/larrychen20011120/hateful-meme-project>。

5 結果與討論

5.1 實驗結果探討

5.1.1 多模態 CLIP 方法

✓ 提示詞對 CLIP 零樣本分類的影響

提示詞的實驗設計包括正/負詞彙設計 ($\mathcal{W}_{pos}/\mathcal{W}_{neg}$) 和提示詞的開頭，基於 CLIP 預訓練資料種類非常多，因此我額外設計 The meme content is 開頭的提示詞，希望能藉此方法提示 CLIP 提取適當的圖像理解能力。如[表五]所示，CLIP 在惡意迷因的零樣本分類整體的表現非常差，而且正負例的提示詞對零樣本分類有很大的影響。例如：以(normal, hate)作為分類字詞時有最好的表現，而用(normal, bad)幾乎無法鑑別正負樣本。此外，使用 The meme content is 作為開頭的效果提升並不明顯。

提示詞開頭	$\mathcal{W}_{pos}$	$\mathcal{W}_{neg}$	Accuracy	Auroc
This is	normal	hate	0.5559	0.5563
	good	bad	0.5220	0.5264
	good	hate	0.5320	0.5472
	normal	bad	0.4980	0.5286

The meme content is	normal	hate	0.5280	0.5735
	good	bad	0.4983	0.5025
	good	hate	0.5040	0.5522
	normal	bad	0.5260	0.5326

表五、提示詞對 CLIP 零樣本分類的表現影響。

✓ CLIP 微調與零樣本差異

CLIP 在原論文中強調其零樣本分類的效果非常強大，特別是物件辨識、圖像分類的能力出眾，但從本次實驗結果可以發現到在迷因任務上並沒有辦法直接移轉預訓練知識，而且 CLIP 可能對於詞彙的意義理解的能力較差，所以難以真正知道 normal 與 hate 的實際意義。然而直接將模型用參數去擬合就可以有比較好的表現了。

	Method	Accuracy	Auroc
CLIP	Zero-shot	0.5559	0.5563
	Finetune	0.6649	0.7612

表六、CLIP 微調與零樣本對照。

5.1.2 BERT-based 方法

✓ 外部知識帶來的效果提升

由下表能夠清楚看出特徵對提示學習的重要性。其中以圖像描述能夠帶來的效益最低。當引入種族資訊時有非常大的影響力，實體與 HurtLex 也多少都對分類有些幫助。綜合所有外部特徵後，無論語言模型的種類都能有最好的分類表現。

語言模型	外部特徵	Accuracy	Auroc
BERT-based	迷因文字	0.5620	0.6580
	迷因文字、圖片描述	0.5701	0.6606
	迷因文字、圖片描述、種族	0.6500	0.7629
	迷因文字、圖片描述、種族、實體	0.6725	0.7612
	迷因文字、圖片描述、種族、實體、 HurtLex	0.6820	0.7731
HateBERT	迷因文字	0.5660	0.6713
	迷因文字、圖片描述	0.5740	0.6706
	迷因文字、圖片描述、種族	0.6467	0.7010
	迷因文字、圖片描述、種族、實體	0.6480	0.7245
	迷因文字、圖片描述、種族、實體、 HurtLex	0.6793	0.7842

表七、外部特徵對提示學習的影響力。

✓ 微調與提示學習的差異

從表格中能看出微調的效能普遍較差，而且穩定性也不太好。像是對於 HateBERT 來說，用相同的訓練參數就容易微調到過擬合的狀況，使得表現較其他三者都要差勁。

	Method	Accuracy	Auroc
BERT	Prompt	0.6820	0.7731
	Finetune	0.6220	0.7465
HateBERT	Prompt	0.6793	0.7812
	Finetune	0.5600	0.6242

表八、提示學習與微調參數對語言模型的影響。

5.1.3 與其他方法比較

除了比較本研究提出的方法與自身方法間的差異外，我也將其與當前最先進的方法（state-of-the-art）、典型方法以及人類表現進行了比較，以便理解其發展潛力。結果顯示，本研究提出的方法與當前最先進的模型相比，仍存在一定的準確度差距。然而，就模型參數量和訓練環境而言，本研究的方法仍然具有競爭力。它僅需要非常少量的微調時間和相對較少的儲存空間，就能夠取得不錯的效果。

Type	Method		Accuracy	Auroc	Model Size
	Human		0.8470		
Baseline	Unimodal Text BERT		0.5827	0.6505	0.11B
	Concat BERT		0.5932	0.6588	> 0.11B
	ViLBERT		0.6316	0.7217	> 0.11B
	Visual BERT		0.6501	0.7414	> 0.11B
	Flamingo Few-shot			0.7000	80B
SOTA	PaLI-X-VPD		0.8080	0.8920	55B
	RGCL - HateCLIPper		0.7880	0.8670	> 1.1B
	HateCLIPper - Align			0.8580	1.1B
	Flamingo Finetune			0.8660	80B
My methods	CLIP	Zero-shot	0.5559	0.5563	0.43B
		Finetune	0.6649	0.7612	
	BERT	Prompt	0.6820	0.7731	0.11B
		Finetune	0.6220	0.7465	
	HateBERT	Prompt	0.6793	0.7812	0.11B
		Finetune	0.5600	0.6242	


表九、各種方法之綜合比較。

5.2 錯誤分析

由於分類器的評價指標為 Auroc，我根據了 Youden's J Statistic[26]尋找出最佳的分類域值以評斷模型的分類結果而非典型的 0.5 作為域值，Youden's J Statistic 的數學定義如下：

$$Youden's J = \frac{TP}{TP + FN} + \frac{TN}{TN + FP} - 1 = TPR - FPR \quad (13)$$

Youden's J 統計量可以視為 ROC 曲線座標差值，而差值最大的點就是分類最佳的域值，我再以此點來判斷模型預測正確與錯誤的資料，進行錯誤分析。



圖十三、HateBERT 結合所有外部特徵的 ROC-Curve。其中紅色的點就是最佳域值（有最大的 Youden's J 統計量）、橘色則是隨機預測的結果。

5.2.1 錯誤統計

✓ CLIP 與 HateBERT 方法對比

我對比了在測試集上使用兩種方法的各類別準確率，以探討 CLIP 和語言模型之間的差異[圖十四]。結果顯示，相對於 CLIP，語言模型能夠更好地辨識非惡意迷因，但對於惡意迷因的辨識能力幾乎不存在。相反，語言模型的方法通過合理利用外部知識，顯著提升了模型對惡意迷因的辨識能力，同時只造成了一般迷因辨識能力的輕微下降。


除了粗略的比較 CLIP 和 HateBERT 方法的分類差異外，我也利用[5]提供的額外資訊來分析模型錯誤的迷因種類。從[圖十五]可清楚地發現性別與種族的錯誤率下降非常多，也應證 5.1.2 加入種族與性別資訊時，能有非常高的性能提升。而其他種類的分類表現也都比 CLIP 好，只有在非攻擊性迷因的界別能力比 CLIP 還要差。

我認為這樣的結果與訓練資料的比例有非常大的關係，因為根據 CLIP 和 HateBERT 的結果可以看出，兩者都在非惡意的分類上表現較好。由於原訓練資料有較多的非惡意迷因導致模型會學習到較多的非惡意資訊。然而，HateBERT 因為有額外的外部知識，使其能夠更好地利用更多的訊息來做出決策，在非惡意迷因的分類上表現比 CLIP 更好。


✓ HateBERT 有無外部特徵對比

另外，我也對有無外部特徵的語言模型方法探討同樣的事。結果顯示[圖十四]，相較於引入外部特徵，語言模型在非惡意迷因的辨識能力幾乎相同，但對於惡意迷因的辨識能力完全相反了，準確度近乎低於 0.5。

我也同樣利用[5]提供的額外資訊來分析模型錯誤的迷因種類。從[圖十五]可清楚地發現性別與種族的錯誤率一樣下降非常多，但對於殘缺與國籍反而效果更差，而主要的原因就是沒有顯性的這類知識被引入。此外，我認為實體和 HurtLex 的引入可能是導致模型有能力去識別非惡意迷因的關鍵，透過多餘的資訊來告知模型惡意詞彙的有無，使在無惡意的迷因正確率能更好。



圖十四、三種不同方法對惡意迷因與非惡意的分類正確率。



圖十五、三種不同方法針對不同迷因種類的錯誤數量。

5.2.2 錯誤案例之關鍵字分析

我也去分析語言模型的方法是不是會被一些關鍵字誘導而導致分類錯誤。我根據非惡意與惡意迷因分類錯誤的關鍵字，依 4.1 的分析方法用文字雲的形式呈現，分別繪製了有無外部知識 HateBERT 的文字雲[圖十六][圖十七]。綜合來看，有外部知識者對於含有種族膚色的內容不容易誤判為惡意迷因，而沒有外部知識者在種族議題上就容易誤判。同時，我也發現偏向恐怖攻擊、伊斯蘭以及一些日常生活的文字都是容易誤判的內容，原因就是因為外部知識是有針對性的，例如強調種族、性別議題，而一般的惡意迷因或是沒有提及的議題就不容易分辨。



圖十六、HateBERT 沒添加外部知識分類錯誤的文字雲。左圖為將非惡意迷因分類為惡意迷因的關鍵字、右圖則是將惡意迷因分為非惡意的關鍵字。

可以研究，例如透過訓練來學習 soft prompt 或是給予模型一些較接近的示例，這些方法都有機會來使語言模型的方法達到接近 SOTA 的表現。

6 參考文獻

- [1] 六度分隔理論. (n.d.). 維基百科. <https://zh.wikipedia.org/zh-tw/六度分隔理论>
- [2] 泥仔. (2020, October 14). 【迷因專題 04】地獄梗總是雙重標準？那條充滿彈性的迷因界線. DQ. <https://dq.yam.com/post/13090>
- [3] 靜慧. (2020, November 5). 迷因現象省思. Medium. <https://medium.com/artech-interpreter/迷因現象省思-f3082f180e8b>
- [4] Kiela, D., Firooz, H., Mohan, A., Goswami, V., Singh, A., Ringshia, P., & Testuggine, D. (2020). The hateful memes challenge: Detecting hate speech in multimodal memes. *Advances in Neural Information Processing Systems*, 33, 2611-2624.
- [5] Mathias, L., Nie, S., Davani, A. M., Kiela, D., Prabhakaran, V., Vidgen, B., & Waseem, Z. (2021, August). Findings of the WOAHS 5 shared task on fine grained hateful memes detection. In *Proceedings of the 5th Workshop on Online Abuse and Harms (WOAH 2021)* (pp. 201-206).
- [6] Bassignana, E., Basile, V., & Patti, V. (2018). Hurtlex: A multilingual lexicon of words to hurt. In *CEUR Workshop proceedings* (Vol. 2253, pp. 1-6). CEUR-WS.
- [7] Muennighoff, N. (2020). Vilio: State-of-the-art visio-linguistic models applied to hateful memes. *arXiv preprint arXiv:2012.07788*.
- [8] Zhou, Y., Chen, Z., & Yang, H. (2021, July). Multimodal learning for hateful memes detection. In *2021 IEEE International Conference on Multimedia & Expo Workshops (ICMEW)* (pp. 1-6). IEEE.
- [9] Alayrac, J. B., Donahue, J., Luc, P., Miech, A., Barr, I., Hasson, Y., ... & Simonyan, K. (2022). Flamingo: a visual language model for few-shot learning. *Advances in Neural Information Processing Systems*, 35, 23716-23736.
- [10] Cao, R., Lee, R. K. W., Chong, W. H., & Jiang, J. (2023). Prompting for multimodal hateful meme classification. *arXiv preprint arXiv:2302.04156*.
- [11] Wu, Q., Wang, P., Shen, C., Dick, A., & Van Den Hengel, A. (2016). Ask me anything: Free-form visual question answering based on knowledge from external sources. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 4622-4630).
- [12] Yichao, W. A. N. G., Muhua, Z. H. U., Chen, X. U., Yan, Z. H. A. N. G., Huizhen, W. A. N. G., & Jingbo, Z. H. U. (2022). Exploiting image captions and external knowledge as representation enhancement for VQA. *Journal of Tsinghua University (Science and Technology)*, 62(5), 900-907.
- [13] Koufakou, A., Pamungkas, E. W., Basile, V., & Patti, V. (2020). HurtBERT: Incorporating

- lexical features with BERT for the detection of abusive language. In Proceedings of the fourth workshop on online abuse and harms (pp. 34-43). Association for Computational Linguistics.
- [14] Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2018). Bert: Pre-training of deep bidirectional transformers for language understanding. arXiv preprint arXiv:1810.04805.
 - [15] Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., ... & Stoyanov, V. (2019). Roberta: A robustly optimized bert pretraining approach. arXiv preprint arXiv:1907.11692.
 - [16] Gururangan, S., Marasović, A., Swayamdipta, S., Lo, K., Beltagy, I., Downey, D., & Smith, N. A. (2020). Don't stop pretraining: Adapt language models to domains and tasks. arXiv preprint arXiv:2004.10964.
 - [17] Caselli, T., Basile, V., Mitrović, J., & Granitzer, M. (2020). Hatebert: Retraining bert for abusive language detection in english. arXiv preprint arXiv:2010.12472.
 - [18] Baltrušaitis, T., Ahuja, C., & Morency, L. P. (2018). Multimodal machine learning: A survey and taxonomy. *IEEE transactions on pattern analysis and machine intelligence*, 41(2), 423-443.
 - [19] Li, L. H., Yatskar, M., Yin, D., Hsieh, C. J., & Chang, K. W. (2019). Visualbert: A simple and performant baseline for vision and language. arXiv preprint arXiv:1908.03557.
 - [20] Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., ... & Sutskever, I. (2021, July). Learning transferable visual models from natural language supervision. In *International conference on machine learning* (pp. 8748-8763). PMLR.
 - [21] Li, J., Li, D., Xiong, C., & Hoi, S. (2022, June). Blip: Bootstrapping language-image pre-training for unified vision-language understanding and generation. In *International Conference on Machine Learning* (pp. 12888-12900). PMLR.
 - [22] Liu, P., Yuan, W., Fu, J., Jiang, Z., Hayashi, H., & Neubig, G. (2023). Pre-train, prompt, and predict: A systematic survey of prompting methods in natural language processing. *ACM Computing Surveys*, 55(9), 1-35.
 - [23] Gao, T., Fisch, A., & Chen, D. (2020). Making pre-trained language models better few-shot learners. arXiv preprint arXiv:2012.15723.
 - [24] Ding, N., Hu, S., Zhao, W., Chen, Y., Liu, Z., Zheng, H. T., & Sun, M. (2021). Openprompt: An open-source framework for prompt-learning. arXiv preprint arXiv:2111.01998.
 - [25] Karkkainen, K., & Joo, J. (2021). FairFace: Face Attribute Dataset for Balanced Race, Gender, and Age for Bias Measurement and Mitigation. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision* (pp. 1548-1558).
 - [26] Youden's J Statistic. (n.d.). Wikipedia. https://en.wikipedia.org/wiki/Youden%27s_J_statistic